

The Butterfly Effect

Identificação Automatizada de Espécies de Lepidoptera para Monitorização da Biodiversidade no Museu de Ciência

Projeto 1 - Aprendizagem Computacional Avançada

Gabriela Hoffmann Roxo e Flavia Brito Reis

Faculdade de Ciências e Tecnologia, Universidade de Coimbra, Portugal
uc2025245410@student.uc.pt e uc2025192825@student.uc.pt

Resumo Este trabalho apresenta o desenvolvimento de um sistema de classificação automática de espécies de Lepidoptera utilizando técnicas de aprendizagem profunda, com o objetivo de apoiar a monitorização da biodiversidade no Museu de Ciência da Universidade de Coimbra. O conjunto de dados disponibilizado contém 5199 imagens distribuídas por 75 espécies distintas, apresentando elevada variabilidade intra-classe e desequilíbrio entre categorias.

Foram exploradas as arquiteturas sugeridas: um Multi-Layer Perceptron (MLP), uma Convolutional Neural Network (CNN) e uma ResNet18, avaliadas com diferentes funções de perda (CrossEntropyLoss e Multi-MarginLoss) e otimizadores (Adam e RMSprop). Adicionalmente, foi investigada uma arquitetura ResNet50 pré-treinada como trabalho extra, com o objetivo de analisar o impacto do transfer learning no desempenho e obter melhor acurácia para o resultado final.

Os resultados mostram que os modelos convolucionais apresentam desempenho superior ao MLP, confirmando a importância da extração automática de características espaciais. Entre os modelos base, a ResNet18 apresentou o melhor desempenho. A ResNet50 pré-treinada, incluída como experimento extra, obteve a maior capacidade de generalização, atingindo a melhor performance no conjunto de validação.

Keywords: Aprendizagem Profunda · Classificação de Imagens · Lepidoptera · Redes Neurais Convolucionais.

1 Introdução

A monitorização da biodiversidade desempenha um papel fundamental na conservação dos ecossistemas e na compreensão das alterações ambientais. No contexto dos museus de ciência e de projetos de investigação ecológica, a identificação manual de espécies pode ser um processo demorado, sujeito a erro humano e dependente de especialistas.

Com o avanço das técnicas de visão computacional e aprendizagem profunda, tornou-se possível automatizar tarefas de classificação de imagens com

elevada precisão. Redes Neurais Convolucionais (CNNs), introduzidas por LeCun et al. [2] e amplamente popularizadas após os avanços de Krizhevsky et al. [3], tornaram-se o paradigma dominante na extração automática de padrões visuais complexos. Arquiteturas mais recentes, como as ResNets [4], expandiram esta abordagem ao permitir modelos mais profundos e expressivos.

Neste trabalho é abordado o problema da classificação automática de espécies de Lepidoptera (borboletas) a partir de imagens. O conjunto de dados disponibilizado contém 5199 imagens distribuídas por 75 espécies distintas, apresentando boa variabilidade intra-classe e leve desequilíbrio entre categorias, o que permite explorar seu impacto na classificação.

O objetivo é desenvolver e comparar diferentes arquiteturas de redes neurais capazes de identificar corretamente a espécie presente em cada imagem. Para esse fim, foram explorados três modelos sugeridos pelo enunciado: um Multi-Layer Perceptron (MLP), uma Convolutional Neural Network (CNN) e uma arquitetura baseada em ResNet18. Adicionalmente, foi investigada uma arquitetura mais profunda pré-treinada (ResNet50, treinada no ImageNet-1K) como extensão experimental, permitindo analisar o impacto de técnicas modernas de *transfer learning* [5] no desempenho. Os modelos foram treinados e avaliados utilizando o framework PyTorch, comparando diferentes funções de perda e algoritmos de otimização nos modelos base, enquanto a ResNet50 pré-treinada foi utilizada exclusivamente como trabalho extra.

2 Descrição da Abordagem

A abordagem seguida neste trabalho consiste no desenvolvimento de um pipeline completo de classificação de imagens utilizando redes neurais profundas. O projeto disponibilizou um notebook inicial contendo a classe *ButterflyDataset*, responsável pelo carregamento das imagens e respectivas etiquetas a partir do ficheiro *train.csv*. Este código serviu de base para a construção do pipeline experimental.

O conjunto de dados inclui 5199 imagens RGB distribuídas por 75 classes. Todas as imagens foram convertidas para RGB, redimensionadas para uma resolução configurável (por omissão, 64×64 píxeis) e transformadas em tensores PyTorch através de *torchvision*. O dataset foi dividido em treino (80%) e validação (20%) utilizando divisão estratificada, garantindo preservação da distribuição das classes. Para melhorar a capacidade de generalização, foram aplicadas técnicas de *data augmentation*, incluindo rotações, inversões horizontais, *color jitter* e *random resized crops*. No caso da ResNet50 pré-treinada, optou-se por uma estratégia de aumento de dados mais leve, preservando características aprendidas durante o pré-treino e reduzindo o custo computacional.

Como ilustrado na Figura 1, o dataset apresenta elevada variabilidade visual entre espécies. A Figura 2 evidencia ainda um pequeno desequilíbrio entre classes.

Foram exploradas três arquiteturas sugeridas pelo enunciado: um Multi-Layer Perceptron (MLP), uma Convolutional Neural Network (CNN) e uma ResNet18 [4]. O MLP opera sobre a imagem achatada e serve como *baseline*. A CNN segue



Figura 1. Exemplos do dataset de Lepidoptera.




Figura 2. Distribuição do número de imagens por classe.

uma estrutura tradicional com camadas convolucionais, ReLU e *max pooling*, permitindo extrair padrões espaciais relevantes. A ResNet18 constitui a arquitetura mais profunda entre os modelos obrigatórios, oferecendo maior capacidade de generalização. Como extensão experimental, foi ainda investigada uma arquitetura mais profunda pré-treinada, a ResNet50 (ImageNet-1K), permitindo analisar o impacto de técnicas modernas de *transfer learning* [5] no desempenho.

Cada arquitetura base foi treinada com diferentes combinações de funções de perda (*CrossEntropyLoss* e *MultiMarginLoss*) e otimizadores (*Adam* e *RMS-prop*), totalizando 12 experiências independentes. Todas as experiências compartilharam os mesmos parâmetros de treino, assegurando comparabilidade direta entre configurações. A ResNet50 pré-treinada foi treinada separadamente, utilizando *CrossEntropyLoss* com *label smoothing* e o otimizador *AdamW*, refletindo práticas comuns em *transfer learning*.

A avaliação dos modelos foi realizada principalmente através da *accuracy* no conjunto de validação (v_acc), métrica adotada como critério principal de comparação entre arquiteturas. Adicionalmente, foram registradas as curvas de *training loss* e *validation loss*, permitindo analisar a estabilidade do treino e a ocorrência de sobreajuste. Para o melhor modelo entre os obrigatórios, bem como para a extensão experimental, foram ainda calculadas métricas por classe, *precision*, *recall*, *F1-score* e *support*, possibilitando uma análise mais granular do comportamento do classificador. A partir destas métricas, foram identificadas as cinco classes com melhor e pior desempenho em cada categoria, destacando padrões de acerto e dificuldade do dataset.

Ferramentas de IA foram utilizadas de forma auxiliar. O GitHub Copilot sugeriu trechos de código posteriormente modificados e integrados manualmente. O Microsoft Copilot Chat apoiou a revisão de bugs, organização do pipeline, modularização do código, redação da documentação e na formatação dos resultados de acordo com o modelo *submission.csv* enviado ao *kaggle*. Todas as decisões técnicas e implementação final foram realizadas pelas autoras.

3 Configuração Experimental

Todas as experiências foram conduzidas em PyTorch, utilizando uma configuração comum de hiperparâmetros para garantir comparabilidade entre modelos. As imagens foram redimensionadas para 64×64 píxeis nos modelos base (MLP, CNN e ResNet18) e para 224×224 no caso da ResNet50 pré-treinada. O tamanho do *batch* foi fixado em 32 (6 PT), o número de épocas em 50 e a semente aleatória em 42, assegurando reprodutibilidade. Os hiperparâmetros foram definidos de forma configurável, permitindo ajustar a carga computacional e adaptar a abordagem experimental sem alterar a metodologia. Os modelos obrigatórios foram treinados em CPU, enquanto o experimento adicional com a ResNet50 pré-treinada foi executado em GPU devido ao maior custo computacional.

Tabela 1. Hiperparâmetros experimentais utilizados.

Hiperparâmetro	Base	ResNet50 Pré-treinada
Tamanho da imagem	64×64	224×224
Batch size	32	16
Épocas totais	50	50
Épocas do backbone	—	5
Learning rate inicial	0.001	0.001
Weight decay	1×10^{-4}	1×10^{-4}
Função de perda	CE, MM	CE + LS (0.1)
Otimizador	Adam, RMSprop	AdamW
Scheduler	ReduceLROnPlateau	OneCycleLR
Patience (early stop)	8	8
Seed	42	42
Dispositivo	CPU	GPU

Foram avaliadas combinações entre duas funções de perda (*CrossEntropyLoss* e *MultiMarginLoss*) e dois otimizadores (*Adam* e *RMSprop*), totalizando 12 experiências para os modelos obrigatórios. Para a arquitetura pré-treinada (ResNet50), utilizou-se *CrossEntropyLoss* com *label smoothing* e o otimizador *AdamW*, refletindo práticas comuns em *transfer learning*. O parâmetro *weight decay* foi definido como 10^{-4} .

A estratégia de treino incluiu *early stopping* com *patience* de 8 épocas, monitorizando a *acurácia de validação*. O agendamento da taxa de aprendizagem dependeu do tipo de modelo: para arquiteturas pré-treinadas utilizou-se *OneCycleLR*, enquanto para os modelos base foi aplicado *ReduceLROnPlateau* com *patience* de 3 e fator de redução de 0.5.

As previsões foram obtidas diretamente através das operações de *softmax* e *argmax* do PyTorch, evitando implementações manuais. Para a ResNet50, o treino foi dividido em duas fases: cinco épocas de ajuste do *backbone* com camadas congeladas, seguidas de *fine-tuning* completo.

As transformações aplicadas incluíram *data augmentation* moderado nos modelos base e uma versão mais leve para a arquitetura pré-treinada, preservando

as representações aprendidas no ImageNet. As transformações consistiram em redimensionamento, *RandomResizedCrop*, inversão horizontal, pequenas rotações, variação de cor e normalização com as médias e desvios padrão do ImageNet.

4 Análise de Resultados

Esta seção apresenta a avaliação quantitativa e qualitativa dos modelos treinados, considerando tanto as arquiteturas base (MLP, CNN e ResNet18) quanto o modelo adicional pré-treinado (ResNet50). Os resultados são analisados em múltiplas dimensões: desempenho global, comportamento durante o treino, métricas por classe e padrões de erro observados na matriz de confusão. A comparação entre modelos permite identificar não apenas diferenças de desempenho, mas também o impacto de fatores como profundidade da arquitetura, uso de *transfer learning*, estratégias de *data augmentation* e mecanismos de regularização. A análise é complementada por uma discussão sobre classes mais fáceis e mais difíceis, bem como sobre a influência da distribuição do dataset no comportamento dos modelos.

4.1 Desempenho Global dos Modelos

A Figura 5 apresenta, lado a lado, o ranking dos modelos avaliados e as curvas de acurácia de validação ao longo do treino. Esta disposição permite observar simultaneamente o desempenho final e o comportamento dinâmico de cada arquitetura.

Ranking dos modelos:

1. ResNet50PT_CrossEntropyPT_ADAMW: Acc: 0.9538
2. ResNet_CrossEntropy_ADAM: Acc: 0.7644
3. ResNet_CrossEntropy_RMSprop: Acc: 0.7433
4. ResNet_MultiMargin_ADAM: Acc: 0.7317
5. ResNet_MultiMargin_RMSprop: Acc: 0.7000
6. CNN_CrossEntropy_RMSprop: Acc: 0.6750
7. CNN_CrossEntropy_ADAM: Acc: 0.6337
8. CNN_MultiMargin_ADAM: Acc: 0.6135
9. CNN_MultiMargin_RMSprop: Acc: 0.6000
10. MLP_CrossEntropy_ADAM: Acc: 0.4154
11. MLP_CrossEntropy_RMSprop: Acc: 0.3923
12. MLP_MultiMargin_ADAM: Acc: 0.3846
13. MLP_MultiMargin_RMSprop: Acc: 0.3567




Figura 3. Ranking (Best Acc).

Figura 4. Curvas de validação dos modelos.

Figura 5. Resumo global dos resultados: ranking e curvas de validação.

Os resultados mostram uma hierarquia entre as famílias de modelos. As CNNs (com acurácias entre 0.60 e 0.675) superam os experimentos MLP (com valores entre 0.3567 e 0.4154), refletindo a capacidade das convoluções em capturar padrões espaciais relevantes. A ResNet18 apresenta o melhor desempenho entre os modelos sem pre-treino, alcançando *validation accuracy* de 0.764. O modelo adicional pré-treinado (ResNet50) apresenta a curva mais elevada e estável,

confirmando o impacto positivo do *transfer learning* em cenários com variabilidade visual.

Embora não esteja representado nas curvas de validação, avaliou-se também o uso do *WeightedRandomSampler*. Os testes preliminares mostraram que o sampler produziu apenas uma variação marginal e, em alguns casos, ligeiramente pior em relação ao treino convencional. Dado o baixo nível de desequilíbrio do dataset (razão 1.84), optou-se por removê-lo das experiências finais.

4.2 Curvas de Treino e Validação

A Figura 10 apresenta as curvas de *training loss* e *validation accuracy* das melhores combinações dos modelos treinados. É possível notar a evolução das curvas, seguindo a evolução dos modelos no que se refere a atividade de classificação. As distancias entre as curvas de treino e validacao vão convergindo: loss diminuindo, ao passo que a acurácia vai aumentando, chegando a melhores convergências com ResNet.




Figura 6. MLP_CE_Adam




Figura 7. CNN_CE_RMSPProp




Figura 8. ResNet18_CE_Adam




Figura 9. ResNet50_CE_AdamW PT.

Figura 10. Curvas de treino e validação dos modelos ResNet18 e ResNet50 pré-treinada.

Comparando as Figuras 6 e 7 é possível concluir que a rede CNN foi superior à rede MLP. O MLP apresentou maior tendência ao *overfitting*, com aumento contínuo da acurácia de treino sem correspondente melhoria na validação, refletindo suas limitações estruturais na captura de padrões espaciais [6]. Por outro lado, a CNN demonstrou curvas mais estáveis, com melhor generalização e convergência mais rápida, resultado das camadas convolucionais, que permitem a extração hierárquica de características visuais relevantes, como bordas e texturas, melhorando o desempenho em tarefas de classificação de imagens. A função de perda da CNN apresentou uma redução mais suave e consistente ao longo das épocas, indicando otimização mais eficiente.

Esses resultados preparam o cenário para modelos mais avançados, apresentados nas Figuras 8 e 9. As curvas de *training loss* e *validation accuracy* dos dois modelos com melhor desempenho: a ResNet18 treinada do zero e a ResNet50 pré-treinada. A comparação entre ambas evidencia dois regimes de aprendizagem fundamentalmente distintos.

A ResNet18 inicia o treino a partir de pesos aleatórios e, portanto, apresenta uma trajetória de aprendizagem mais gradual. A acurácia de validação cresce de forma consistente ao longo das épocas, estabilizando apenas na segunda metade do treino. Embora exija mais iterações para convergir, o modelo demonstra boa capacidade de generalização para uma arquitetura treinada do zero, alcançando aproximadamente 0.764 de *validation accuracy*. Já a ResNet50 pré-treinada(ImageNet), por outro lado, apresenta um comportamento distinto: após algumas épocas iniciais dedicadas ao ajuste do *backbone*, o início do *fine-tuning* completo resulta num salto imediato de desempenho. Já na primeira época de treino, a acurácia de validação ultrapassa 0.87. A curva é mais suave, estável e elevada desde o início, refletindo a vantagem de partir de filtros previamente otimizados em larga escala. O uso de *OneCycleLR* acelera a convergência inicial e evita oscilações abruptas, contribuindo para uma trajetória de treino mais eficiente. O modelo atinge um desempenho final de 0.9538, em cerca de 30 épocas, o melhor entre todas as arquiteturas avaliadas.

A comparação direta evidencia que, embora a ResNet18 apresente um desempenho sólido para um modelo treinado do zero, a ResNet50 pré-treinada opera num regime superior desde as primeiras iterações. A diferença entre as curvas ilustra de forma clara o impacto do *transfer learning* reduzindo o tempo de convergência e elevando substancialmente o desempenho final.

4.3 Análise por Classe

A Figura 13 apresenta métricas de *precision*, *recall* e *f1-score* para o melhor modelo base (ResNet18 treinada do zero) e para o melhor modelo pré-treinado (ResNet50). A análise revela diferenças marcantes entre as duas arquiteturas, tanto no desempenho global quanto na distribuição de erros entre as classes.

Desempenho do melhor modelo base: A ResNet18 treinada do zero apresenta um padrão mais heterogêneo. Entre as classes com melhor desempenho destacam-se *Atala* (0.97), *AN 88* (0.96), *Red Postman* (0.96), *Crimson Patch* (0.96) e *Banded Orange Heliconian* (0.93). Estas espécies possuem padrões visuais marcantes, com coloração saturada e formas bem definidas, o que facilita a separação mesmo sem pré-treino. No entanto, as classes mais difíceis apresentam *f1-scores* substancialmente inferiores, como *Copper Tail* (0.50), *Purplish Copper* (0.50), *Clouded Sulphur* (0.48), *Tropical Leafwing* (0.45) e *Large Marble* (0.38). Nestes casos, a combinação de baixa distinção visual, variação intra-classe e semelhança com outras espécies limita a capacidade do modelo em construir representações discriminativas a partir de pesos aleatórios.

ResNet_CrossEntropy_ADAM

	precision	recall	f1-score	support
ATALA	1.000000	0.937500	0.967742	16.0
AN 88	1.000000	0.928571	0.962963	14.0
RED POSTMAN	1.000000	0.928571	0.962963	14.0
CRIMSON PATCH	0.923077	1.000000	0.960000	12.0
BANDED ORANGE HELICONIAN	1.000000	0.866667	0.928571	15.0
...	...	...	...	...
COPPER TAIL	0.470588	0.533333	0.500000	15.0
PURPLISH COPPER	0.538462	0.466667	0.500000	15.0
CLOUDED SULPHUR	0.444444	0.533333	0.484848	15.0
TROPICAL LEAFWING	0.555556	0.384615	0.454545	13.0
LARGE MARBLE	0.500000	0.307692	0.380952	13.0

Figura 11. ResNet18 base.

Melhor modelo encontrado: ResNet50PT_CrossEntropyPT_ADAM

	precision	recall	f1-score	support
AFRICAN GIANT SWALLOWTAIL	1.000000	1.000000	1.000000	12.0
AMERICAN SNOOT	1.000000	1.000000	1.000000	12.0
APPOLLO	1.000000	1.000000	1.000000	14.0
AN 88	1.000000	1.000000	1.000000	14.0
BECKERS WHITE	1.000000	1.000000	1.000000	13.0
...	...	...	...	...
EASTERN COMA	0.916667	0.733333	0.814815	15.0
CLOUDED SULPHUR	0.750000	0.800000	0.774194	15.0
LARGE MARBLE	0.687500	0.846154	0.758621	13.0
PURPLISH COPPER	0.619048	0.866667	0.722222	15.0
COPPER TAIL	0.750000	0.600000	0.666667	15.0

Figura 12. ResNet50 pre-treinada.

Figura 13. Desempenho por classe - Top e Bottom Classes.

Desempenho do melhor modelo pré-treinado: A ResNet50 pré-treinada apresenta desempenho excepcional, com diversas classes atingindo *f1-score* igual a 1.00, incluindo *African Giant Swallowtail*, *American Snoot*, *Appollo*, *AN 88* e *Beckers White*. Estes resultados indicam separabilidade quase perfeita no espaço de características, refletindo a capacidade do modelo em capturar padrões morfológicos distintos mesmo em classes com suporte reduzido. Entre as classes mais desafiadoras, observam-se valores ainda elevados, como *Eastern Coma* (0.81), *Clouded Sulphur* (0.77), *Large Marble* (0.76), *Purplish Copper* (0.72) e *Copper Tail* (0.66). Mesmo nestes casos, o modelo mantém desempenho robusto, sugerindo que as confusões residuais estão associadas a similaridades visuais finas ou a elevada variabilidade intra-classe.



Figura 14. Exemplos de erros de classificação ResNet50.

Comparação entre modelos. A diferença entre os dois modelos é evidente: enquanto a ResNet18 apresenta um gradiente claro entre classes fáceis e difíceis, a ResNet50 reduz drasticamente essa disparidade, elevando o desempenho de praticamente todas as classes para níveis elevados. O pré-treino permite que o modelo capture nuances morfológicas finas, como padrões de veios, texturas e variações de coloração, que são difíceis de aprender do zero com um dataset de tamanho moderado. Assim, a análise por classe reforça a conclusão de que o

transfer learning não apenas melhora o desempenho global, mas também reduz desigualdades de desempenho entre classes, tornando o modelo mais consistente e confiável.

4.4 Matriz de Confusão

A Figura 16 apresenta a matriz de confusão do melhor modelo. Observa-se uma forte concentração de valores na diagonal principal, refletindo elevada precisão na maioria das classes. As confusões residuais ocorrem principalmente entre espécies com padrões visuais semelhantes, como *Purplish Copper*, *Copper Tail* e *Clouded Sulphur*, que apresentam coloração neutra e menor contraste estrutural.




Figura 15. ResNet18-CE-ADAM.




Figura 16. ResNet50-CE-ADAMW




Figura 17. Comparação das matrizes de confusão - melhores combinações.

No modelo base (ResNet18), a matriz de confusão revela um padrão mais disperso, com erros mais frequentes entre classes morfológicamente próximas. A

comparação entre as duas matrizes evidencia que o pré-treino não apenas melhora o desempenho global, mas também reduz significativamente a sobreposição entre classes, tornando as fronteiras de decisão mais nítidas e estáveis.

A Figura 17 mostra as melhores combinações entre os modelos testados, ordenados pela acurácia apresentada em cada modelo. É possível notar a evolução e a melhor definição das classes.

4.5 Fase de Teste e Geração do Arquivo de Submissão

Após a seleção do melhor modelo: ResNet50 pré-treinada com *CrossEntropy* e otimizador AdamW, procedeu-se à etapa de inferência sobre o conjunto de teste. Esta fase teve como objetivo avaliar a capacidade do modelo em generalizar para dados completamente não vistos durante o treino e validação.

O processo consistiu em carregar o modelo final, aplicar o mesmo pré processamento utilizado no treino e gerar, para cada imagem do conjunto de teste, a classe prevista. As previsões foram organizadas no arquivo `*submission*.csv`, contendo o identificador da imagem e a respectiva classe atribuída pelo modelo.

Os arquivos foram submetidos à competição no Kaggle, que funciona como *ground truth* externo e permitiu comparar o desempenho do modelo com outras abordagens. O resultado revelou uma disparidade significativa entre as duas abordagens testadas. O modelo ResNet50 pré-treinado alcançou um desempenho superior, com um score de 0.9407, garantindo a 10^a posição no ranking da competição. Isso evidencia a eficácia do *transfer learning*, que permitiu ao modelo aproveitar características visuais complexas extraídas do *dataset* e adaptar-se às características visuais específicas que definem as diferentes espécies de borboletas. Em contrapartida, o modelo ResNet18 (base) apresentou um desempenho inferior (0.7307). Essa diferença sugere que uma arquitetura mais simples e treinada do zero carece da capacidade de abstração necessária para distinguir espécies que possuem padrões visuais quase idênticos, ao mesmo tempo em que ignora variações irrelevantes como iluminação ou ângulo dentro da mesma espécie.

A geração do `resultado.csv` encerra o ciclo de experimentação, demonstrando que o modelo não apenas alcança elevado desempenho em validação, mas também está operacionalmente preparado para inferência em novos dados.

4.6 Discussão Final

Os resultados obtidos mostram a importância de um pipeline de treino estruturado para tarefas de classificação de imagens. A comparação entre modelos treinados do zero e modelos pré-treinados demonstra que a profundidade da arquitetura e a qualidade da inicialização podem impactar agressivamente o desempenho final.

Os modelos base revelaram uma hierarquia clara: MLPs apresentaram limitações estruturais significativas, incapazes de capturar padrões espaciais relevantes; CNNs ofereceram melhorias substanciais, mas ainda insuficientes para lidar

com a diversidade visual do dataset; e as ResNets, mesmo treinadas do zero, mostraram-se mais eficazes devido às conexões residuais e maior profundidade. A ResNet18, em particular, destacou-se como o melhor modelo base, alcançando 0.7644 de acurácia de validação.

A introdução do *transfer learning* elevou o desempenho. A ResNet50 pré-treinada não apenas convergiu mais rapidamente, como também atingiu 0.9538 de acurácia, reduzindo drasticamente a disparidade entre classes fáceis e difíceis. A análise por classe e as matrizes de confusão confirmam que o pré-treino melhora a consistência do modelo, convergindo mais rapidamente, mitigando confusões recorrentes e fortalecendo a separabilidade entre espécies visualmente semelhantes.

A evolução entre as rodadas de treino, aumento do número de épocas, modificações no data augmentation, *learning rate scheduling* e *fine-tuning*, auxiliaram o desempenho final.

5 Conclusão

Este trabalho apresentou uma análise de diferentes arquiteturas de redes neurais aplicadas à classificação de espécies de Lepidoptera. Através de um pipeline modular e progressivamente refinado, foi possível demonstrar o impacto de técnicas modernas de treino, como *data augmentation*, *learning rate scheduling* e *transfer learning* no desempenho dos modelos.

Os resultados mostram que, embora modelos treinados do zero possam alcançar desempenhos competitivos, o uso de arquiteturas pré-treinadas oferece vantagens substanciais, especialmente em datasets com elevada variabilidade visual e tamanho moderado. A ResNet50 pré-treinada destacou-se como a melhor solução, atingindo 0.9538 de acurácia de validação e apresentando desempenho consistente em praticamente todas as classes.

A ResNet50 pré-treinada destacou-se como a melhor solução, atingindo 0.9538 de acurácia de validação e apresentando desempenho consistente em praticamente todas as classes. Além do elevado desempenho global, o modelo demonstrou estabilidade, rápida convergência e capacidade de capturar nuances morfológicas finas que os modelos treinados do zero não conseguiram aprender. A combinação entre profundidade, inicialização informada e *fine-tuning* permitiu reduzir drasticamente as confusões entre classes visualmente semelhantes, tornando a ResNet50 não apenas a arquitetura mais precisa, mas também a mais robusta e confiável para aplicação prática.

Referências

1. Lourenço, N., Carvalho, P., Cortés, G., Correia, J.: The Butterfly Effect. Advanced Machine Learning 2025/2026, University of Coimbra (2026).
2. LeCun, Y., Bottou, L., Bengio, Y., Haffner, P.: Gradient-based learning applied to document recognition. Proceedings of the IEEE 86(11), 2278–2324 (1998).

3. Krizhevsky, A., Sutskever, I., Hinton, G.E.: ImageNet classification with deep convolutional neural networks. In: Advances in Neural Information Processing Systems, pp. 1097–1105 (2012).
4. He, K., Zhang, X., Ren, S., Sun, J.: Deep residual learning for image recognition. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 770–778 (2016).
5. Yosinski, J., Clune, J., Bengio, Y., Lipson, H.: How transferable are features in deep neural networks? In: Advances in Neural Information Processing Systems, pp. 3320–3328 (2014).
6. Damle, Abhishek.: Comparing the Performance of CNN and MLP in Image Classification. (2020)

Anexos

Anexo A — Arquivos de Previsões Padronizados

Como parte dos resultados experimentais, foram gerados dois arquivos de submissão formatados de acordo com os requisitos da plataforma kaggle (1300 registros e identificação por `filename`). Estes arquivos representam as previsões finais de cada arquitetura testada:

1. **submission_modelo_base.csv**: Contém as previsões da arquitetura **ResNet18** treinada do zero (score 0.7307).
2. **submission_modelo_pretreino.csv**: Contém as previsões da arquitetura **ResNet50** com pesos pré-treinados, que atingiu o desempenho superior (score 0.9407) e a 10^a posição no ranking.

Conteúdo anexado ao relatório.