

We Need More Butterflies

Data Augmentation via Modelos Generativos Condicionais para a Classificação de Alta Granularidade de Lepidoptera Projeto 2 — Aprendizagem Computacional Avançada

Gabriela Hoffmann Roxo e Flavia Brito Reis

Faculdade de Ciências e Tecnologia, Universidade de Coimbra, Portugal
uc2025245410@student.uc.pt e uc2025192825@student.uc.pt

Resumo Este trabalho investiga o impacto de modelos generativos profundos como estratégia de aumento de dados numa tarefa de classificação de imagens de alta granularidade (75 espécies de Lepidoptera). A investigação seguiu uma trajetória cronológica em dois estágios: numa primeira fase, exploramos modelos condicionais (cGAN e C-VAE) treinados sobre a totalidade das 75 classes; perante os resultados insatisfatórios, transitamos para uma abordagem específica por classe, treinando Autoencoders e GANs clássicas isoladamente sobre três classes das mais sub-representadas. A qualidade das imagens sintéticas foi avaliada através de métricas FID, IS e SSIM. Em ambas as fases, a introdução de dados sintéticos degradou a acurácia do classificador face à Baseline com augmentação clássica — na Fase 2, com a arquitectura correcta do enunciado, a Baseline atingiu 83.64% de validação contra 78.85% (CNN + GAN) e 78.08% (CNN + AE). Os resultados sugerem que, na ausência de modelos generativos de alta fidelidade, as técnicas clássicas de aumento de dados superam a síntese generativa em robustez e eficácia.

Keywords: Deep Generative Models · GAN · Autoencoder · Data Augmentation · Lepidoptera Classification

1 Introdução

A classificação de imagens de lepidópteros em alta granularidade — 75 espécies distintas a partir de aproximadamente 5200 imagens — constitui um cenário interessante para o treino de redes neurais convolucionais. A variância intra-classe, combinada com a escassez de amostras por espécie, motiva a exploração de estratégias de aumento de dados que vão além das transformações geométricas e fotométricas clássicas.

Neste trabalho, investigamos a utilização de modelos generativos profundos como mecanismo de síntese de novas amostras de treino para uma **Baseline**CNN pré-definida, cujos parâmetros de arquitetura, otimizador e função de custo foram mantidos fixos ao longo de todos os experimentos.

A investigação decorreu em duas fases motivadas por resultados empíricos. Numa primeira fase, treinaram-se modelos condicionais — *Conditional GAN*

(cGAN) e *Convolutional Variational Autoencoder* (C-VAE) — sobre a totalidade das 75 classes, na expectativa de modelar a distribuição conjunta do dataset. Observou-se, contudo, que estas arquiteturas tendiam a convergir para representações médias das classes, perdendo as características taxonômicas finas que distinguem as espécies. Esta limitação motivou uma segunda fase: o treino de arquiteturas não-condicionais (Autoencoders e GANs clássicas) isoladamente sobre as três classes mais sub-representadas, com o objetivo de extrair padrões específicos em cenários de extrema escassez amostral.

2 Descrição da Abordagem

2.1 Processamento de Dados e Classificador Base

O conjunto de dados é composto por 5199 imagens RGB de 75 espécies de borboletas. O particionamento foi efetuado de forma estratificada em 70% para treino, 15% para validação e 15% para teste, preservando a proporção de classes em cada partição.

A **BaselineCNN** fornecida pelo enunciado consiste em três blocos convolucionais, com *Batch Normalization* e *ReLU*, seguidos de *Max Pooling*. Após *Adaptive Average Pooling*, o classificador é composto por três camadas densas com expansão progressiva intercaladas por *ReLU* e *Dropout* (0.5). Para o conjunto de treino, aplicaram-se transformações de augmentação clássica: rotações até $\pm 15^\circ$, inversões horizontais aleatórias e *color jitter*. O treino inclui *early stopping* com *patience* de 15 épocas.

Na Fase 1 (modelos condicionais) foi utilizada por inadvertência uma versão simplificada da **BaselineCNN** com apenas um *Conv2d* por bloco, em vez de dois. Esta inconsistência foi detectada durante a Fase 2, onde se passou a utilizar a arquitetura correcta do enunciado. Os resultados das duas fases não são directamente comparáveis entre si — a Baseline da Fase 1 (76.92% de teste) é inferior à da Fase 2 (83.64% de validação) precisamente por esta razão. Contudo, a compão interna a cada fase permanece válida: em ambos os casos, a augmentação generativa degradou a performance face à Baseline correspondente.

2.2 Fase 1 — Abordagem Condicional (75 Classes)

A primeira estratégia consistiu em modelar a distribuição conjunta de todas as classes através de dois modelos condicionais, treinados sobre o dataset completo.

A **cGAN condicional** incorpora um gerador baseado em *ConvTranspose2d* que recebe um vetor latente de dimensão 256 (configuração padrão) concatenado com um *embedding* de classe de dimensão 100, produzindo imagens 64×64 via ativação *Tanh*. O discriminador utiliza *Spectral Normalization* em todas as camadas convolucionais para estabilização do treino, sendo otimizado via *Hinge Loss*. Os pesos foram inicializados com média 0 e desvio padrão 0.02 para camadas convolucionais, e média 1 e desvio padrão 0.02 para camadas de *Batch Normalization*, seguindo as recomendações DCGAN.

O **C-VAE condicional** utiliza um encoder com quatro blocos Conv2d que projeta a imagem de entrada num vetor latente de dimensão 256 (via reparametrização), condicionado ao *embedding* de classe na fase de decodificação. A função de custo é o ELBO (combinação de BCE estrutural e divergência KL), com *KL Annealing*: o coeficiente β cresce linearmente de 0 até 1.0 ao longo das primeiras 30 épocas, mitigando o fenómeno de *posterior collapse*. O decoder produz saídas no intervalo $[0, 1]$ via ativação *Sigmoid*.

Foi ainda explorada uma configuração **híbrida** que concatenou amostras sintéticas de ambos os modelos (cGAN + C-VAE) no conjunto de treino, avaliando se a combinação das duas fontes generativas compensava as fraquezas individuais de cada arquitetura. Os resultados reportados na Secção 4 correspondem ao treino com dimensão latente de 128, que demonstrou convergência mais estável face à configuração com 256.




Figura 1. Imagens geradas pela CVAE e CGAN - tendência a média - exemplo classe Yellow Tail.

2.3 Fase 2 — Abordagem Específica por Classe (3 Classes)

Perante a tendência de *blurring* estatístico observada nos modelos condicionais — resultante da convergência para médias de classe ao otimizar sobre 75 distribuições simultaneamente, am alternativa foi desenvolvido o treino isolado de arquiteturas não-condicionais sobre três das classes mais sub-representadas no dataset: GOLD BANDED, MALACHITE e CRIMSON PATCH.

O raciocínio subjacente foi o seguinte: ao eliminar o condicionamento e treinar sobre amostras de uma única classe, o modelo seria forçado a aprender os padrões taxonómicos específicos dessa espécie, sem a pressão de generalizar para as restantes 74 classes.

Foram treinados dois tipos de arquiteturas por classe:

- **Autoencoder Convolutacional (ButterflyAutoencoder64)**: arquitectura encoder-decoder simétrica com quatro estágios de convolução. O encoder reduz progressivamente a resolução de 64×64 até um gargalo espacial de $1 \times 1 \times 256$ através de convoluções com stride 2 e uma camada final com kernel 8×8 . O decoder reconstrói a imagem por transposição inversa. Todas as camadas intermédias utilizam *Batch Normalization* e *LeakyReLU* (slope 0.2); a saída do decoder usa *Sigmoid*. A função de custo é MSE entre a reconstrução e a imagem original.
- **GAN clássica não-condicional (Generator64 / Discriminator64)**: gerador DCGAN com cinco blocos *ConvTranspose2d* que expande um vetor

latente de dimensão 128 até $64 \times 64 \times 3$ via *Tanh*. O discriminador é uma rede convolucional com cinco blocos Conv2d e activação final linear (sem Sigmoid), optimizado via *BCEWithLogitsLoss*. Sem qualquer mecanismo de condicionamento por classe — o treino isolado por espécie substitui o condicionamento explícito.

Foi ainda treinado um **VAE isolado** (*ButterflyVAE64*), por analogia com o C-VAE da Fase 1. As imagens geradas apresentaram SSIM sistematicamente inferior ao Autoencoder em todas as classes (0.07–0.09 vs. 0.11–0.15), confirmando que introduz ruído que agrava o *blurring*. Por esta razão, o VAE isolado foi excluído da fase de augmentação da CNN, sendo os seus resultados reportados apenas para comparação.

O pipeline de integração das imagens sintéticas ao conjunto de treino da **BaselineCNN** foi utilizado exclusivamente para *data augmentation*. No caso das imagens condicionais, foram integradas 80 amostras sintéticas, enquanto que para os geradores isolados foram geradas e integradas 47 imagens, com o objetivo de nivelar as classes sub-representadas face à classe mais avantajada. Em ambos os casos, a totalidade das imagens geradas foi utilizada no treino. No caso da GAN isolada, a estratégia de treino seguiu duas etapas: numa primeira fase, o modelo foi treinado sobre a totalidade do dataset de borboletas, permitindo-lhe aprender estruturas visuais gerais comuns às espécies; numa segunda fase, procedeu-se a um *fine-tuning* isolado sobre cada uma das três classes sub-representadas, de modo a especializar o gerador nos padrões taxonómicos específicos de cada espécie. Esta abordagem visou combinar a capacidade de generalização estrutural adquirida no treino geral com a especificidade necessária para reproduzir as características distintivas de cada classe. Numa execução posterior, foi testada a utilização de apenas 20% dessas imagens (aproximadamente 10 por classe), desta vez aplicando uma filtragem por qualidade — seleccionando as amostras com maior valor de SSIM relativamente às imagens reais da classe correspondente (*Top-K* por qualidade) — com o intuito de aferir se o volume de amostras sintéticas estaria a introduzir ruído excessivo. Os resultados não revelaram diferenças significativas, sugerindo que o fator mais limitante não era a quantidade de imagens geradas, mas sim a sua qualidade, a qual se mostrou determinante no desempenho do modelo.

3 Configuração Experimental

Todas as experiências foram conduzidas em PyTorch, com semente aleatória fixada em 42 e execução em GPU quando disponível. Os hiperparâmetros foram centralizados na classe **ProjectConfig**, garantindo reprodutibilidade entre experiências. A Tabela 1 resume os valores utilizados.

A estratégia de avaliação dos geradores assentou em três métricas complementares: *Fréchet Inception Distance* (FID), que mede a distância entre as distribuições das imagens sintéticas e reais no espaço de características de uma rede Inception-v3; *Inception Score* (IS), que quantifica a qualidade e diversidade




Figura 2. Pipeline de integração de imagens sintéticas para treino da **BaselineCNN**. O caminho superior (linha sólida) representa as execuções em que a totalidade das imagens geradas foi utilizada diretamente; o caminho inferior (linha tracejada) corresponde à execução final, onde foi aplicada uma filtragem *Top-K* por SSIM sobre aproximadamente 10 imagens por classe.

das amostras geradas; e *Structural Similarity Index* (SSIM), que mede a fidelidade geométrica pixel-a-pixel das reconstruções. Para o classificador, a métrica principal foi a acurácia de validação e de teste.

4 Análise de Resultados e Discussão

4.1 Fase 1 — Modelos Condicionais (75 Classes)

Métricas de fidelidade. Os modelos condicionais produziram valores de FID elevados em ambas as arquiteturas: 317.53 para a cGAN e 342.68 para o C-VAE (Tabela 2). Valores de FID superiores a 300 indicam uma distância substancial entre as distribuições de características das imagens sintéticas e reais, evidenciando que os geradores não conseguiram reproduzir fielmente a variabilidade visual das 75 espécies.

O C-VAE obteve adicionalmente um SSIM médio de 0.42, o que corresponde à perda de mais de 57% da fidelidade estrutural pixel-a-pixel. Este resultado é uma consequência direta da otimização via erro a nível de pixel (BCE estrutural): ao penalizar desvios médios sobre todas as classes simultaneamente, o decodificador converge para soluções de compromisso que produzem imagens com *blurring* severo — removendo as componentes de alta frequência espacial responsáveis pelos padrões taxonômicos finos.

Impacto na CNN. A introdução de dados sintéticos condicionais degradou a performance do classificador em todas as configurações face à Baseline (Tabela 4, Figura 3). No conjunto de teste, a CNN + cGAN obteve 74.62%, a CNN + C-VAE 72.44%, e a configuração híbrida (cGAN + C-VAE simultaneamente) 71.92%, contra os 76.92% da Baseline. A convergência mais lenta e a maior instabilidade das curvas de validação são consistentes com a injeção de padrões estocásticos incoerentes no espaço de decisão do classificador. A configuração

Tabela 1. Hiperparâmetros experimentais utilizados no pipeline. Fase 1: modelos condicionais (75 classes). Fase 2: modelos isolados (3 classes).

Hiperparâmetro	CNN	cGAN cond.	C-VAE cond.	AE / GAN isolado
Tamanho imagem	64×64	64×64	64×64	64×64
Batch size	32	32	32	32
Épocas máximas	120	200	80	120 / 80
Learning rate	$5-10 \times 10^{-4}$	1×10^{-4}	3×10^{-4}	$5 \times 10^{-4} / 2 \times 10^{-4}$
Otimizador	Adam	Adam	AdamW	Adam
Betas (Adam)	(0.9, 0.999)	(0.0, 0.9)	(0.9, 0.999)	(0.9, 0.999)
Dimensão latente	—	256 / 128*	256 / 128*	128
Dim. embedding	—	100	100	—
Função de perda	Cross-Entropy	Hinge Loss	ELBO (BCE+KL)	MSE / BCEWithLogits
Early stopping	15 épocas	—	10 épocas	10 épocas (AE)
Gradient clipping	—	1.0	1.0	—
Amostras sintéticas	—	80/classe	80/classe	47/classe
Seed	42	42	42	42

*Resultados reportados correspondem ao treino com dim=128.

Tabela 2. Métricas de qualidade dos modelos condicionais (75 classes).

Modelo	FID ($\downarrow$)	SSIM Médio ($\uparrow$)
cGAN Condicional (Hinge Loss)	317.53	—
C-VAE Condicional (ELBO)	342.68	0.4217

híbrida — que acumulou amostras sintéticas de ambas as arquiteturas — produziu o pior resultado de teste (71.92%), confirmando o efeito cumulativo da sobreposição de dois geradores de baixa fidelidade. Para uma tarefa *fine-grained* onde as distinções taxonômicas assentam em contornos de asas, a diluição do dataset com amostras de $FID > 300$ compromete a geometria das fronteiras de decisão da rede.

4.2 Fase 2 — Modelos Isolados (3 Classes)

Métricas de fidelidade. A Tabela 3 apresenta os resultados das três arquiteturas treinadas isoladamente sobre as classes GOLD BANDED, MALACHITE e CRIMSON PATCH. Os valores de FID mantêm-se elevados (327–396), mas é notória a superioridade do Autoencoder em termos de SSIM face à GAN isolada e ao VAE isolado. A GAN isolada alcançou os menores FID por classe (355.82–381.80), enquanto o VAE isolado produziu os SSIM mais baixos (0.07–0.09), confirmando a decisão de não o utilizar na fase de augmentação.

Os valores de IS próximos de 1.0 em todos os modelos refletem a baixa diversidade das amostras sintéticas — esperada, dado que cada gerador foi treinado sobre uma única classe com poucas dezenas de imagens reais. Este cenário de




Figura 3. Curvas de acurácia de validação para as quatro configurações da Fase 1. A Baseline apresenta convergência mais estável e acurácia final superior.

Tabela 3. Métricas de qualidade dos modelos isolados por classe (3 classes).

Modelo	Classe	FID (↓)	IS (↑)	SSIM (↑)
3*Autoencoder	Gold Banded	373.38	1.0451	0.1452
	Malachite	367.23	1.0520	0.0906
	Crimson Patch	327.40	1.0377	0.1184
3*VAE isolado	Gold Banded	395.84	1.0504	0.0874
	Malachite	369.91	1.0573	0.0695
	Crimson Patch	387.05	1.0560	0.0844
3*GAN isolada	Gold Banded	357.41	1.0243	0.1171
	Malachite	381.80	1.0228	0.0839
	Crimson Patch	355.82	1.0214	0.0939

escassez amostral favoreceu o sobreajuste dos geradores, que tenderam a memorizar as amostras disponíveis em vez de generalizar a distribuição da classe.

Impacto na CNN. O treino da **BaselineCNN** com o dataset aumentado pelos modelos isolados produziu os melhores resultados generativos do projeto (Figura 5, Tabela 4). A CNN + GAN isolada atingiu 78.85% de validação, e a CNN + AE isolado 78.08% — ambos acima de qualquer configuração condicional, mas abaixo da Baseline desta fase (83.64%). A proximidade entre as duas curvas sugere que AE e GAN introduziram níveis de ruído comparáveis, não havendo vantagem clara de uma arquitetura sobre a outra neste regime de escassez. A Baseline manteve-se consistentemente acima ao longo de todo o treino, com convergência mais estável e sem os episódios de degradação visíveis nas curvas com dados sintéticos.




Figura 4. Grid comparativo imagens sintéticas vs reais - AE / VAE / GAN




Figura 5. Curvas de acurácia de validação para a Fase 2: Baseline (83.64%), CNN + AE isolado (78.08%) e CNN + GAN isolada (78.85%). Apesar de superiores aos modelos condicionais, ambas as abordagens ficam aquém da Baseline.

4.3 Discussão Geral

Avaliando os resultados, percebemos que, em ambas as fases, a augmentação por síntese generativa não superou a augmentação clássica. A análise dos modelos ao longo das duas fases permite compreender os mecanismos específicos de falha de cada arquitetura. A cGAN condicional foi o primeiro modelo a revelar os limites da abordagem. Com 75 classes a competir simultaneamente pelo sinal de gradiente, o gerador convergiu para a produção de uma única imagem representativa por classe, com variabilidade quase nula entre amostras. Este colapso de modo (*mode collapse*) é a manifestação clássica de um discriminador demasiado forte num espaço de classes demasiado vasto — o gerador aprende a enganar o discriminador com uma solução de compromisso estável, em vez de explorar a diversidade intra-classe. O C-VAE condicional manifestou um problema distinto mas igualmente prejudicial: em vez de colapsar para uma única amostra, tendia para a média estatística da classe. A reparametrização estocástica produziu reconstruções inconsistentes mesmo dentro de uma mesma espécie — imagens que não partilhavam os padrões taxonómicos específicos da classe, mas antes uma

Tabela 4. Comparação de acurácia do classificador em todas as configurações experimentais. As duas fases não são directamente comparáveis: a Fase 1 usou inadvertidamente uma versão simplificada da BaselineCNN (ver Secção 2). A comparação interna a cada fase permanece válida.

Fase	Configuração	Val Acc	Test Acc
Fase 1			
4*Condicional	Baseline (augmentação clássica)	74.49%	76.92%
	CNN + cGAN condicional	72.44%	74.62%
	CNN + C-VAE condicional	72.56%	72.44%
	CNN + Híbrido (cGAN + C-VAE)	74.10%	71.92%
Fase 2			
3*Isolado	Baseline (augmentação clássica)	83.64%	83.46
	CNN + AE isolado (3 classes)	78.08%	78.72%
	CNN + GAN isolada (3 classes)	78.85%	78.59%

fusão suavizada de todas as amostras de treino. O SSIM de 0.42 confirma esta perda estrutural: mais de metade da informação de alta frequência foi destruída pela optimização via erro pixel-a-pixel, que penaliza igualmente todos os desvios independentemente da sua relevância perceptual. A transição para a abordagem isolada por classe na Fase 2 mitigou parcialmente o problema, mas trouxe os seus próprios desafios. Nos primeiros treinos da GAN isolada, o modelo chegou a zerar completamente algumas vezes. A substituição de ReLU por LeakyReLU nas camadas intermédias resolveu o problema de forma satisfatória: o gradiente residual para activaões negativas manteve o gerador a aprender. Foram ainda exploradas estratégias adicionais de estabilização — ajuste assimétrico das *learning rates* entre gerador e discriminador e múltiplos passos de actualização do discriminador por iteração — mas conduziram rapidamente a sobreajuste e foram abandonadas. A estratégia adoptada de pré-treino geral seguido de *fine-tuning* por classe visou contornar a escassez amostral, aproveitando as estruturas visuais comuns a todas as espécies antes de especializar o modelo nas três classes sub-representadas — ainda assim insuficiente para compensar a baixa diversidade disponível ao nível da classe individual. Foi ainda considerada a utilização do F1 como critério de selecção das imagens geradas, direccionando mais amostras para as classes onde o classificador mais errava. A ideia foi abandonada por uma razão prática: as classes sub-representadas eram precisamente as fronteiras de decisão mais frágeis do modelo, e adicionar imagens com *blur* dessas mesmas espécies amplificaria os padrões ambíguos que o classificador já tinha dificuldade em separar — reforçando o problema em vez de o mitigar. Esta escassez é um factor limitante. Com poucas dezenas de imagens reais por classe, um gerador não dispõe de diversidade suficiente para aprender a distribuição da espécie sem memorizar as amostras disponíveis — e os valores de IS próximos de 1.0 em todos os modelos isolados reflectem exactamente essa condição. As transformações geométricas e fotométricas clássicas não enfrentam este problema: operam sobre amostras reais, preservam a identidade taxonómica e introduzem variabilidade

sem depender de capacidade de generalização. É essa diferença de regime que explica a consistência dos resultados em ambas as fases.

5 Conclusão

Os resultados obtidos nas duas fases confirmam que, no regime de escassez amostral por classe combinado/produzindo geradores pouco robustos, os modelos generativos profundos não constituem um substituto eficaz para a augmentação clássica. A Discussão Geral identifica os mecanismos concretos desta limitação — colapso de modo na cGAN, convergência para a média no C-VAE, e sobreajuste nos modelos isolados — mas a conclusão estrutural é transversal a todas as arquitecturas testadas: imagens sintéticas de baixa fidelidade introduzem ruído num classificador que já opera acima dos 80% de acurácia, degradando a performance face à Baseline correspondente em ambas as fases. Apesar dos vários experimentos e esforço dedicados, cada avanço ou reformulação metodológica reduziu o espaço do problema mas não resolveu a limitação fundamental. Neste sentido, o trabalho contribui não com uma solução, mas com uma análise das condições em que a síntese generativa pode não ser a melhor resposta. Trabalhos futuros podem explorar arquitecturas com funções de perda perceptuais ou modelos de difusão, menos susceptíveis à escassez amostral por operarem em espaços de representação de mais alto nível. Ou ainda, realizar *fine-tuning* exclusivamente sobre os embeddings de classe de uma cGAN pré-treinada, congelando todos os restantes parâmetros: desta forma, o conhecimento estrutural adquirido sobre as 75 espécies seria preservado, e apenas a *instrução* de classe das espécies sub-representadas seria refinada com as amostras adicionais disponíveis.

Referências

1. Lourenço, N., Carvalho, P., Cortés, G., Correia, J.: The Butterfly Effect. Advanced Machine Learning 2025/2026, University of Coimbra (2026).
2. Heusel, M., Ramsauer, H., Unterthiner, T., Nessler, B., Hochreiter, S.: GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium. In: Advances in Neural Information Processing Systems (NeurIPS), pp. 6626–6637 (2017).
3. Wang, Z., Bovik, A.C., Sheikh, H.R., Simoncelli, E.P.: Image quality assessment: from error visibility to structural similarity. IEEE Transactions on Image Processing, 13(4), 600–612 (2004).
4. Radford, A., Metz, L., Chintala, S.: Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks. In: ICLR (2016).
5. Kingma, D.P., Welling, M.: Auto-Encoding Variational Bayes. In: ICLR (2014).
6. Mirza, M., Osindero, S.: Conditional Generative Adversarial Nets. arXiv:1411.1784 (2014).