

Relatório Final do Projeto

Gabriela Hoffmann Roxo e Amine Khalfallah
uc2025245410@student.uc.pt, uc2022215115@student.uc.pt

May 17, 2026

1 Introdução

Este projeto tem como objetivo analisar a atuação dos deputados da Câmara dos Deputados do Brasil, com ênfase na utilização de recursos públicos e na atividade parlamentar ao longo das últimas legislaturas. Com base em dados oficiais da API de Dados Abertos, foi desenvolvido um dashboard interativo para apoiar a análise exploratória e a disseminação de resultados. O estudo busca avaliar a eficiência e a coerência do uso de recursos públicos em relação à produção legislativa e à participação institucional. Apesar de sua natureza pública, esses dados encontram-se dispersos, o que dificulta sua interpretação por diferentes públicos. A ferramenta destina-se a cidadãos, jornalistas, investigadores e organizações da sociedade civil, permitindo a análise comparativa do desempenho parlamentar. Entre as funcionalidades, destacam-se a exploração de gastos por deputado, partido e unidade federativa, a análise da composição das despesas e a relação entre gastos e indicadores de atividade parlamentar, possibilitando a identificação de padrões e outliers. O código-fonte e o pipeline de dados estão disponíveis em: https://github.com/gabrielahf/camara_pipeline.git

2 Trabalhos Relacionados

Este projeto fundamenta-se em princípios de Visualização de Informação e Visual Analytics, bem como em estudos sobre comportamento legislativo no Brasil. A concepção do dashboard segue o Visual Analytics Framework (Keim et al., 2010), integrando técnicas de processamento de dados (como normalização por z-score e agrupamento hierárquico) a visualizações interativas para identificação de padrões e anomalias. O mapeamento visual é orientado pela taxonomia de Munzner (2014), privilegiando posição para variáveis quantitativas e cor/agrupamento para categóricas. No domínio aplicado, a definição de métricas, como custo por atividade, apoia-se em literatura sobre alocação de recursos públicos (e.g., Ipea), que aponta a influência de fatores políticos e eleitorais no comportamento legislativo. Para a análise, utilizam-se técnicas como heatmaps clusterizados, dendrogramas e gráficos de área empilhada, permitindo explorar padrões e dinâmicas temporais.

3 Requisitos de Design

Os requisitos de design foram definidos com base no problema e no público-alvo, estruturando-se em questões analíticas, tarefas de utilizador e diretrizes de implementação. As principais questões analíticas envolvem a distribuição dos gastos entre deputados, partidos e unidades

federativas, a composição das despesas por categoria, a relação entre gastos e atividade parlamentar e a identificação de perfis atípicos. As tarefas centrais incluem filtrar e ordenar deputados por métricas relevantes, comparar partidos e UFs, explorar perfis individuais e investigar casos específicos a partir de diferentes níveis de agregação. Em termos de design, o sistema deve suportar múltiplas vistas coordenadas, incorporar técnicas avançadas de visualização e interação (como brushing and linking), seguir boas práticas de visualização de informação e garantir desempenho adequado para exploração interativa.

4 Dados

Os dados utilizados neste projeto provêm exclusivamente da API de Dados Abertos da Câmara dos Deputados do Brasil. Através de *scripts* em Python, recolhemos informação para as duas legislaturas mais recentes (por omissão, 56 e 57) e para um intervalo de anos definido por variáveis de ambiente, permitindo ajustar facilmente o período de análise.

Foram consideradas quatro fontes principais:

- **Deputados:** metadados dos parlamentares (identificador, nome, partido, UF, situação, entre outros campos), obtidos a partir do endpoint `/deputados`.
- **Despesas:** registros de despesas individuais de cada deputado, incluindo tipo de despesa, valor líquido e data, obtidos do endpoint `/deputados/{idDeputado}/despesas`.
- **Proposições:** proposições legislativas associadas a cada deputado, obtidas via `/proposicoes` com filtro por autor.
- **Eventos:** participação em eventos oficiais (sessões, comissões, etc.) através do endpoint `/deputados/{idDeputado}/eventos`.

O *script* `fetch.py` trata da paginação, repetição com *backoff* e armazenamento incremental dos dados brutos em ficheiros Parquet na pasta `data/raw/`, com mecanismos de *checkpoint* para permitir retomar descargas interrompidas. Em seguida, `clean.py` aplica regras básicas de limpeza (normalização de tipos, tratamento de valores em falta, identificação de estornos) e grava versões limpas em `data/processed`. Finalmente, o `build_dataset_modelagem.py` integra estas tabelas num *dataset mestre* ao nível do deputado, agregando:

- `gasto_total` e `gasto_liquido` (somatórios de valores positivos e líquidos);
- `qtd_despesas` e `qtd_estornos`;
- `total_proposicoes` e `total_eventos`;
- colunas de gasto por macro-categoria (por exemplo, `gasto_transporte`, `gasto_divulgacao`), derivadas de uma categorização heurística baseada em palavras-chave; 1
- métricas derivadas como `atividade_composta`, `gasto_total_ajustado`, `sem_despesa` e `custo_por_atividade`.

O resultado final é armazenado em `dataset_mestre_clean.parquet` e `dataset_mestre_clean.csv`, que constituem a base principal tanto para a análise exploratória como para o *dashboard* em Plotly/Dash.




Figure 1: Distribuição de gastos por macro-categoria na Câmara

5 Análise Exploratória de Dados (EDA)

A análise exploratória foi conduzida em Python, utilizando principalmente as bibliotecas Pandas e Plotly, com o objetivo de compreender a distribuição das variáveis principais, detectar outliers e avaliar relações entre gastos e atividade parlamentar. Para facilitar a integração futura no *dashboard*, os gráficos gerados foram exportados em formato HTML, JSON e PNG.

A partir do `dataset_mestre_clean`, o `script eda.py` aplica uma etapa de pré-processamento que garante tipos numéricos consistentes, cria uma transformação logarítmica de `gasto_total` (`log_gasto_total`) e define faixas de gasto para comparações categóricas. Em seguida, são geradas várias famílias de visualizações:

- **Distribuições e outliers:** histogramas de `gasto_total` e `log_gasto_total`, e *boxplots* para `gasto_total`, `atividade_composta` e `custo_por_atividade`, permitindo identificar a assimetria das distribuições e casos extremos.
- **Comparações por grupo:** gráficos de barras e *boxplots* por partido e por unidade federativa (`siglaPartido`, `siglaUf`), explorando variação entre grupos.
- **Relações entre variáveis:** *scatter plot* de `log_gasto_total` vs. `atividade_composta`, com linha de tendência linear e destaque para deputados com maior `custo_por_atividade`; além de um *heatmap* de correlações entre as principais métricas numéricas.
- **Composição de despesa:** *heatmap* partido vs. macro-categoria de despesa, *treemaps* hierárquicos (partido → UF → deputado, e partido → categoria) e gráfico de área empilhada ao longo do tempo, usando o `despesas_categorizadas.csv`.
- **Perfis e anomalias:** coordenadas paralelas para inspecionar perfis multivariados de deputados, gráficos tipo *beeswarm* por partido e tabelas de anomalias com os deputados de maior gasto, maior custo por atividade ou maior número de estornos.

Estas visualizações suportam diretamente as decisões de design do *dashboard*. Por exemplo, a forte assimetria de `gasto_total` motivou o uso de escalas logarítmicas em algumas vistas; a importância de combinar gasto com atividade levou à métrica 2 `custo_por_atividade` como

indicador central; e a riqueza da dimensão categoria-partido justificou o uso de visões avançadas como *treemaps* e *heatmaps*, que serão reutilizadas ou adaptadas na implementação final.




Figure 2: Nível de gasto e a atividade parlamentar

6 Design

A fase de design deste projeto foi orientada pela necessidade de transformar dados brutos da API da Câmara em representações visuais que favoreçam a identificação rápida de padrões de gastos e produtividade.

6.1 Fundamentação Teórica e Escolhas de Representação

As visualizações implementadas no código (`eda.py`) foram definidas com base na hierarquia de eficácia de Cleveland e McGill e na taxonomia de Munzner (2014). Para variáveis quantitativas como `gasto_total` e `atividade_composta`, privilegiou-se o uso de gráficos de dispersão e barras com posição em escala comum, o canal mais preciso para comparação de magnitudes.

Devido à assimetria dos dados (distribuição *long-tail*), aplicou-se a transformação logarítmica ($\log(1 + x)$) na função `plot_histograms`, melhorando a expressividade ao evitar a compressão visual dos dados. Para representar a hierarquia `Partido` $\rightarrow$ `UF` $\rightarrow$ `Deputado`, adotaram-se *treemaps*, que permitem visualizar relações parte-todo de forma compacta e sem navegação complexa.

6.2 Integridade Gráfica

Seguindo os princípios de Tufte (2001), buscou-se minimizar elementos não informativos. O uso do *template* `plotly_white` reduz ruídos visuais e enfatiza os dados.

A interatividade foi incorporada por meio de *tooltips* (*hover_data*), permitindo detalhamento sob demanda sem comprometer a clareza visual, em linha com o princípio de *details-on-demand*.

6.3 Iteração de Soluções

Durante o desenvolvimento, gráficos de barras empilhadas foram testados para representar gastos por partido, mas descartados devido à poluição visual causada pela alta cardinalidade.

A solução final, baseada em **beeswarm/strip plots** (`plot_beeswarm_activity_by_party`), mostrou-se mais eficaz ao evidenciar a distribuição individual dos deputados e evitar o mascaramento de *outliers* por métricas agregadas.

7 Implementação

A implementação do sistema foi dividida em duas frentes principais: um pipeline de processamento de dados robusto e uma interface visual interativa. A solução utiliza a linguagem *Python* como base, integrando as bibliotecas **Pandas** para manipulação de dados e **Plotly/Dash** para a construção do painel de controle.

7.1 Elementos de Design e Layout

O painel foi estruturado para suportar o fluxo de análise "Visão Geral Primeiro, Zoom e Filtragem depois" (*Overview First, Zoom and Filter*), seguindo os princípios de design de interfaces para visualização de dados:

- **Layout de Painel Único (*Dashboard*):** A interface organiza-se num esquema de *grid* onde as métricas agregadas (cartões de *KPIs*) ocupam o topo, seguidas por visualizações macroscópicas (como o *Treemap* de gastos) e terminando em vistas detalhadas de correlação.
- **Vistas Coordenadas:** As visualizações foram implementadas de forma a permitir a comparação multidimensional. Por exemplo, enquanto o gráfico de dispersão mostra a relação entre *gasto_total* e *atividade_composta*, o heatmap lateral detalha a composição dessas despesas por categoria.
- **Componentes de GUI:** Utilizamos os **Dash Core Components** (`dcc`) para criar recipientes de gráficos interativos que mantêm o estado da aplicação durante a navegação do utilizador.

7.2 Componentes de Interação

A interatividade permite ao utilizador explorar o dataset da Câmara de forma personalizada. Os principais mecanismos implementados são:

- **Filtros Dinâmicos (*Dropdowns*):** Menus de seleção permitem filtrar o conjunto de dados por *Partido*, *UF* e *Legislatura*. Estes componentes disparam funções de retoma (*callbacks*) que atualizam todos os gráficos simultaneamente, garantindo a consistência da análise.

- **Seleção e Destaque (*Brushing and Linking*):** Ao interagir com o gráfico de dispersão, o utilizador pode identificar deputados específicos. O sistema utiliza o mecanismo de *hover* do Plotly para exibir metadados detalhados (nome, partido, custo por atividade) sem poluir a vista principal.
- **Controlos de Escala:** Foram incluídos seletores para alternar entre escalas lineares e logarítmicas, permitindo uma análise mais precisa de dados com distribuições assimétricas, como as verbas de gabinete.

7.3 Arquitetura do Sistema

A arquitetura segue um modelo de pipeline em camadas, garantindo a escalabilidade do projeto:

1. **Camada de Extração (`fetch.py`):** Consome os dados da API de Dados Abertos da Câmara, lidando com a paginação e limites de requisição.
2. **Camada de Transformação (`clean.py` / `build_dataset_modelagem.py`):** Realiza a limpeza de valores nulos, normalização de tipos e a criação de métricas derivadas, como a *atividade_composta*.
3. **Camada de Visualização (`app.py`):** O servidor Dash atua como o motor de orquestração, processando os inputs do utilizador e renderizando as figuras geradas pela lógica contida no módulo `eda.py`.

O uso de ficheiros `.parquet` como formato de armazenamento intermédio entre o pipeline e a aplicação final foi uma escolha técnica crucial para otimizar o tempo de carregamento e a eficiência de memória do sistema.

8 Avaliação

O processo de avaliação inicial focou-se em validar se as marcas e canais visuais escolhidos permitiam responder às perguntas de investigação definidas. Foram realizados os seguintes procedimentos:

- **Caminhada Cognitiva:** Uma análise passo a passo das funcionalidades de filtragem e exploração para garantir que o fluxo "visão geral → zoom/filtro → detalhes" (Shneiderman, 1996) fosse intuitivo através da interface do Dash.
- **Verificação de Integridade Gráfica:** Avaliou-se o fator de distorção (*lie factor*) nas escalas logarítmicas e a eficácia da métrica *custo_por_atividade* em representar a realidade dos dados sem viés, garantindo que a magnitude visual corresponde à magnitude numérica (Tufte, 2001).
- **Eficácia do Treemap na Visão Geral:** A representação hierárquica provou ser extremamente eficiente para identificar que partidos e estados dominam o volume de gastos, permitindo uma transição suave para o nível individual do deputado através da percepção de áreas proporcionais.
- **Segmentação por Perfis de Atuação:** A integração do algoritmo K-Means (Figura 3) permitiu agrupar parlamentares com comportamentos similares. Visualmente, é possível distinguir grupos como o **Cluster 2** (verde), que apresenta alta produtividade legislativa, versus grupos com alta concentração de gastos e baixa atividade composta, facilitando a identificação de perfis de eficiência.

- **Consistência das Vistas Coordenadas:** A atualização síncrona dos componentes através de *callbacks* permite uma exploração fluida, onde o filtro aplicado num gráfico (ex: partido) é imediatamente refletido na distribuição de categorias de despesa, mantendo o contexto analítico.




Figure 3: Gráfico de dispersão correlacionando Gasto Total e Atividade Composta, segmentados em 5 perfis distintos via clusters K-Means.

9 Reflexão Crítica

A estratégia de visualização adotada foi altamente eficaz, partindo de uma análise macroscópica para uma investigação microscópica do comportamento parlamentar. O uso da biblioteca *Plotly* permitiu superar as limitações de imagens estáticas através de interatividade (*hover* e filtros dinâmicos), enquanto a combinação de análises univariadas e multivariadas garantiu uma visão holística e robusta do conjunto de dados.

9.1 Eficácia e Descobertas com a Visualização

As visualizações transformaram dados tabulares complexos em diagnósticos claros sobre a eficiência e a natureza dos gastos na Câmara:

- **Correlações e Eficiência:** O *Heatmap* de correlação revelou que a variável `gasto_total` possui correlação perfeita (1.00) com o `custo_por_atividade`. Este insight indica que o volume de gastos é o principal motor do custo de produtividade, sugerindo que a produção legislativa não escala linearmente com o aumento de verbas.

- **Dispersão e Consistência Partidária:** Enquanto o gráfico de barras quantifica o volume agregado (destacando o PT), o *Boxplot* revelou a dispersão interna dos partidos. Observou-se que legendas como UNIÃO e PDT apresentam maior amplitude de gastos entre seus membros, indicando perfis menos homogêneos de consumo parlamentar comparados a outros partidos.
- **Composição Hierárquica de Gastos:** O *Treemap* e o *Heatmap* logarítmico permitiram identificar que "Transporte" e "Divulgação do Mandato" são as categorias dominantes de despesa. A escala logarítmica foi crucial para tornar visíveis categorias menores, como "Alimentação", que seriam ignoradas em análises lineares.
- **Perfis Multivariados e Clusterização:** O gráfico de Coordenadas Paralelas, com eixos normalizados $[0 - 1]$, permitiu traçar o "DNA" de gastos de cada legenda. Foi possível identificar, por exemplo, que o partido REPUBLICANOS apresenta um pico em `custo_por_atividade` apesar de não possuir o maior gasto bruto, sinalizando um ponto de atenção em termos de produtividade relativa. Complementarmente, o *Heatmap* clusterizado agrupou partidos por comportamento real de gastos, revelando similaridades operacionais entre siglas como PL e UNIÃO.
- **Contexto Temporal e Geográfico:** O gráfico de área empilhada demonstrou uma estabilidade estrutural na dominância de gastos entre 2023 e 2025. Geograficamente, o mapa coroplético destacou SP e MG como os maiores centros de custo, validando a influência do tamanho das bancadas estaduais no orçamento total.
 - **Dados Externos e Granularidade:** A integração de indicadores socioeconômicos, como o IDH das regiões de base dos deputados, permitiria uma análise de correlação entre o custo parlamentar e o desenvolvimento local. Além disso, a transição da escala anual para a granularidade mensal possibilitaria a identificação de picos de gastos sazonais ou em períodos pré-eleitorais.
 - **Tratamento de Continuidade Partidária:** Uma limitação identificada foi a ausência de tratamento sistemático para a fusão de legendas, especificamente o caso do PSL e DEM, que formaram o partido UNIÃO em 2021. No conjunto de dados atual, esses registros podem aparecer de forma fragmentada, o que distorce a análise de série temporal e a representatividade de gastos acumulados. O mapeamento histórico dessas siglas é uma melhoria futura essencial para garantir que o agrupamento (*clustering*) e os rankings reflitam a realidade política atual.

9.2 Conclusão

Em suma, as visualizações apresentadas transformaram uma base de dados tabular complexa em uma narrativa compreensível. A eficácia do projeto foi comprovada pela capacidade de identificar não apenas o volume bruto de gastos, mas o perfil comportamental e a eficiência relativa de cada grupo político. Através do uso de métricas como o custo por atividade e visualizações avançadas como coordenadas paralelas e heatmaps clusterizados, foi possível extrair insights que seriam invisíveis em análises convencionais. O trabalho estabelece uma base útil para a fiscalização cidadã e para o entendimento da dinâmica financeira do parlamento brasileiro.